

인공지능과 심층학습의 발전사

SKT 미래기술원 | 정상근

1. 인공지능의 시작

1936년 영국의 수학자 튜링은 가상의 기계가 있어, 기계가 스스로 저장공간에 저장된 기호들을 읽어 들여 처리하고, 그 상태에 따라 다른 상태로 전이가 가능하도록 한다면, 어떠한 연산이든지 스스로 처리 가능하다는 것을 이론적으로 증명하였고 이 기계는 ‘튜링 머신’으로 불리게 된다.

컴퓨터의 기본 원리를 제시한 튜링머신의 개념은 이후 폰 노이만등에 의해 “폰 노이만 구조(프로그램 저장방식)”라는 현대 컴퓨터의 기본구조에 적용되었고, 이는 EDSAC이라는 최초의 컴퓨터들 중 하나로 구현된다. 인류 역사상 처음으로 정보처리 기계가 탄생한 것이다.

1950년대 지식인들에게 “사람의 지능적 활동을 대신할 수 있는 기계”라는 것은 인류 역사상 처음 마주친 개념이었을 것이다. 이러한 새로운 경험은 사람의 머리와 마음에서 일어나는 일들을 진지하게 고찰하게 되는 계기로 작용하였다. 즉, 사람의 머리에서 일어나는 일들도 수학, 물리, 화학처럼 “기계적 계산 과정”을 통해 설명할 수 있을 것이라는 생각으로 발전되었고, 결국 “마음은 정보처리과정의 산물이다.”라는 생각이 시작되었다. 이것이 곧 인지과학(Cognitive Science) 그리고 인공지능(Artificial Intelligence, AI)의 시작이다[1].

2. 규칙기반 인공지능

사람의 ‘지적 능력’과 연관된 능력을 이해하고, 기계에 부여하려는 모든 시도를 인공지능이라고 할 수 있다. 그렇기 때문에 인간의 지능을 어떻게 바라볼 것인가에 대한 생각의 차이가 중요한 철학적, 기술적 차이를 만들어 낸다.

1950년대의 연구자들은 지능을 기계적 계산과정으로 설명할 수 있다는 “계산주의”에 근간하여 연구를 진행하였다. 계산을 수행하기 위해서는 계산 과정을

정의하는 기호(Symbol)와 기호들간의 연산에 대한 규칙(Rule)이 정의되어야 하기 때문에, 초기 인공지능 연구는 기호화, 규칙화에 중점을 두는 규칙 기반 인공지능(Rule Based AI)으로 발전하게 된다. 기호주의, 계산주의, Symbolic AI 등은 하나의 뿌리에서 생겨난 개념이라고 할 수 있다.

규칙기반의 AI는 “실세계의 사물과 사상을 어떻게 기호화 할 것인가”에 대한 물음과 이렇게 표현된 “기호들과 규칙을 활용해 어떻게 지능적 추론을 할 수 있을 것인가”에 대한 물음을 답변하려고 노력한다. 전자에 대한 대표적인 답변들이 온톨로지와 같은 지식 표현 체계들이며, 후자에 대한 대표적인 답변이 1차 논리학(First-Order logic)과 같은 추론 기법이라고 할 수 있다[8].

프로그래밍과의 유사성, 인간이 작성하고 읽을 수 있는 형태라는 특징 때문에 규칙기반 AI는 1950년대부터 1980년대까지 전성기를 맞게 된다. 그러나 사람의 지능을 이식한 기계를 만들 수 있을 것이라는 초기의 믿음과는 달리, 상용화 가능 수준에 미달하는 성능과 범용성의 부족으로 인해 규칙기반 AI는 쇠락의 길을 걷게 된다. 이는 규칙기반 AI의 근간을 이루고 있는 생각, 즉 “실세계의 형상들을 모두 기호화 할 수 있는가?”에 대한 물음을 제기하였고 이는 연결주의라는 사고의 흐름으로 발전하게 된다.

3. 연결주의 인공지능

연결주의(Connectionism)는 기호화나 기호조작만으로는 지능을 충분히 설명할 수 없다고 본다. 연결주의자들은 사람의 지능이 두뇌(Brain)를 이루고 있는 신경들 사이의 연결에서부터 출발한다고 보고, 뇌구조 자체를 저수준에서 모델링 한 후 외부의 자극(학습데이터)을 통해 인공두뇌의 구조와 가중치 값을 변형시키는 방식으로 학습을 시도한다[8].

기호주의와 연결주의 인공지능은 사물의 표현방식에서 큰 차이가 있다. ‘사과’라는 사물을 기술할 때

기호주의 방식은 사과를 기호사전 중 하나로 맵핑하여 생각한다. 예를 들어, 다룰 수 있는 기호의 수가 총 3개이고, ‘사과’가 3번 항목에 기술되어 있다면, 사과는 $[0,0,1]$ 으로 표현되는 셈이다. 마찬가지로 ‘배’와 ‘공’을 기호주의 방식으로 표기한다면 각각 $[0,1,0]$, $[1,0,0]$ 으로 표현된다. 하나의 요소만 활성화 된다고 하여 이를 One-Hot Representation 이라고 부른다.

반면, 연결주의에서는 사과라는 사물은 ‘사과’ 하나로 따로 떼서 생각할 수 없으며 다른 모든 정보와 연결되어 있다고 생각한다. 즉, 사과라는 ‘개념’은 필연적으로 과일, 배, 사과나무, 빨간색 등등 사과와 연관된 모든 정보와 연결되어 있어야 한다고 보고, 이를 실수 행렬 형태(Real value vector form)로 표현하려고 한다. 예를 들어, 3차원의 행렬로 사물을 표현하자고 했을 때 사과는 $[45.6, -21.3, 64.2]$ 과 같은 형태로 표현될 수 있으며, 이러한 표현 방식을 Distributed Representation라고 부른다.

신경망 자체를 연결주의에 기반하여 모델링하고, 이를 통해 인공지능을 구현하려고 하는 시도를 신경망 기반 AI 라고 부른다. 1957년에 Perceptron [2]이 최초로 개발 된 후, 범용의 문제에 적용 가능한 형태로 개량한 Multilayer Perceptron[3, 4]으로 발전하였다. 1980년대부터 신경망 기반의 연구와 상용화가 꾸준히 시도되고 일부 영역에서는 성공을 거두었으나, 1990년대 후반에 이르러서는 사양의 길을 걷게 되었다.

신경망 기반 AI의 주요 실패 이유로 계산의 복잡도와 데이터의 부족을 들 수 있다. 신경망의 깊이가 깊어지면 깊어질수록, 차원수가 높으면 높을수록 성능이 올라간다는 것이 이론적으로 증명 되었으나, 당시의 컴퓨팅 파워는 복잡한 구조의 신경망을 충분히 학습시킬 만한 수준이 되지 못했고, 상용가능 수준으로 학습시킬 데이터도 부족하였다.

신경망 기반 AI 의 실패는 복잡한 방식으로 사람의 지능을 낮은 수준부터 높은 수준까지 모사하는 것 보다, 인공지능이 접목되면 좋을 것 같은 실세계의 문제 그 자체만을 잘 파악하고 해결하는 것이 더 중요하고 실용적이라는 생각을 확산시키기 시작하였다.

4. 통계 기반의 인공지능

통계 기반 인공지능은¹⁾ 인간의 지능과 두뇌구조에 대한 고찰이 아닌 인공지능이 풀고자 하는 ‘문제 자체’를 통계적으로 어떻게 풀어내는가에 대한 관심을 더 가진다고 할 수 있다. 오늘 주식을 팔아야 하나 말아야 하나?’ 라는 문제에 대해서, 통계 기반 인공지능은 과거의 모든 주식 데이터들을 수치화 하여 통계적으로 주식의 흐름을 파악하고, 팔게 되면 얼마의 이득과 손해가 될지를 결정하는 순수한 수학 문제로 바꾸어서 해결한다. 이러한 방식에서는 인간의 두뇌구조나 신경망, 인지체계에 대한 고민은 배제하고 순수하게 ‘문제’ 자체만을 통계적으로 모델링한다[8].

일반적으로 순수 통계 기반의 인공지능은 실제 사물을 표현하는 자질의 설계(Feature Design), 통계적 모델에 기반하여 문제를 풀어서 정답과 비교해보는 평가 과정(Evaluation), 정답과의 차이를 반영하여 통계 모델을 계속 갱신해 나가는 최적화 과정(Optimization/Parameter Update) 의 세가지로 구성된다고 볼 수 있다.

주어진 문제의 특성과, 데이터에 따라 구성요소를 어떻게 조합하느냐가 성능을 결정하며, 2000년대 초반부터 현재까지 음성인식, 영상처리, 자연어처리 등 인공지능의 전분야에 걸쳐서 상용 수준의 자질과 통계모델들이 조합되거나 개발되어 왔다.

Support Vector Machine, Maximum Entropy Classifier, 그리고 Conditional Random Field 같은 통계 모델들이 가장 성공적인 통계기반 인공지능 구현 시도라고 할 수 있다.

순수 통계 기반 인공지능은 몇 가지 측면에서 한계점을 가진다. 자질 설계를 직접 사람이 해야 하기 때문에 자질 설계의 수준이 전체 성능을 좌우하며, 풀어내는 과정에서 생기는 결과물을 다른 분야에 활용하는데 어려움을 갖게 된다. 또한 이렇게 찾아낸 자질과 최적화 조합은 다른 영역의 문제에도 적용된다는 보장이 없어 새로운 문제를 풀고자 할 때 기존에 해왔던 과정을 다시 반복해야 하는 한계점을 가지고 있다.

5. 심층학습 : 신경망 기반 AI 의 부활

심층학습(Deep Learning)은 신경망 기반 AI 의 부활이라고 할 수 있다. 2000년 대 초반부터 최근까지 현대 사회는 인터넷과 모바일기기등으로 인한 수많은 연결이 새로 생겨나게 되었고, 이는 대량의 데이터 확보를 가능하도록 하였다. 충분한 양의 데이터와 이를 처리할 만큼의 컴퓨팅 파워의 확보, 그리고 신경망에 대한 이해와 기술발달은, 이론적으로는 훌륭했으나 시대를 앞서 나갔던 신경망 AI 의 부활을 가능케 하였고, 과거의 머신러닝 방법론들은 줄 수 없는 특별한 장점들을 제공해 주었다.

1) 본 기고문에서는 인공지능을 구현할 때 인간의 지능에 대해 고민하지 않고, 순수하게 통계적 방식으로 문제를 풀려고 하는 ‘순수 통계 기반 AI’ 를 ‘통계 기반 AI’라고 명명하였다. 신경망 AI 도 내부적으로 통계적 기법을 다방면에서 활용할 수 있다.

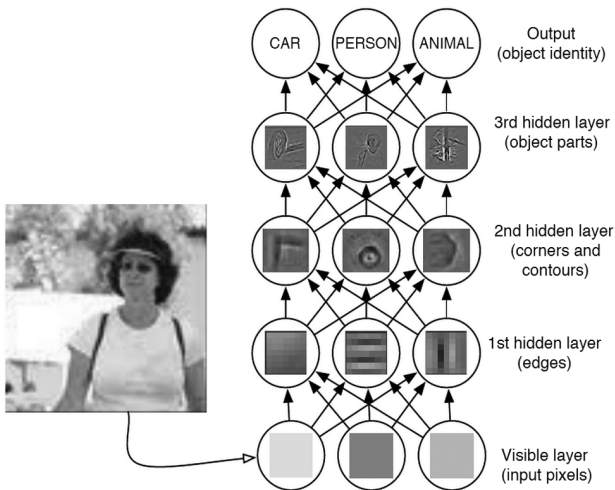


그림 1 이미지 인식에서의 심층학습 절차 및 결과 설명 [5, 6]

첫 번째, 사람이 자질을 직접 디자인 하지 않아도, 충분한 데이터만 있다면 심층학습 스스로 사물의 특징을 발견해 낼 수 있게 되었다. 잘 설계된 여러 계층의 심층학습 모델은 화소(pixel) 정보를 이용해 선을 만들고(contour), 선을 조합해 모양을 만들고, 이러한 모양들을 조합해서 최종 사물을 구분지을 수 있다(그림 1). 모양은 완벽하게 같지만 단지 상하만 뒤집어진 숫자 9와 6을 예로 든다면, 다수의 '9' 이미지를 활용해 학습된 딥러닝 숫자 인식 모델은, 소량의 추가 학습을 통해 숫자 6 역시 잘 인식하게 만들 수 있다.

두 번째, 사물을 Distributed Representation 방식으로 학습해 표현함으로써, 사물의 유사도 정보를 표현 체계 자체에 포함(Embedding) 시킬 수 있게 되었다. 이는 수학적 방식으로 사물의 유사도 계산이 가능하게 됨을 의미한다. 예를 들어, One-Hot Representation을 취하던 기존의 머신러닝 방법에서는 사과[0,0,1], 배[0,1,0], 공[1,0,0] 사이의 유사도가 모두 동일하지만, 심층학습 방법에서는 사과와 배의 거리가 사과와 공보다는 가깝게 표현될 여지가 있다. 이는 심볼이던, 이미지이던, 음성 신호이던지 각 정보들이 행렬형태의 숫자로 변환된 후 수학적 방식으로 정보처리 할 수 있는 가능성이 생겼음을 의미한다.

세 번째, 심층학습은 어느 한 문제를 잘 풀게 되면, 이 과정에서 학습된 데이터를 다른 문제에 그대로 재 활용할 수 있다. 예를 들어, 심층학습 방식을 이용해서 언어모델을 만드는 과정에서 생성된 임베딩 결과는 바로 형태소 분석기 혹은 구문 분석기에 그대로 활용될 수 있다. 또한 형태소 분석 훈련을 통해 학습된 중간단계의 결과물들은 그대로 구문분석이나 번역 문제에 재활용 되거나 직접적으로 연결해서 사용될




그림 2 Google 의 Image Auto Caption 결과물. 두 개의 심층학습 모델을 조합해 이미지를 설명하는 문장을 생성한다[7]

수 있다. 최근 구글은 이미지 분석의 심층학습 결과물과 언어처리용 심층학습 결과물을 하나로 묶어서 이미지를 텍스트로 설명하는 새로운 기술을 선보였다(그림 2).

네 번째, 심층학습은 우리 주변에서 쉽게 구할 수 있는 데이터들을 모두 활용할 수 있는 장점을 제공한다. 심층학습은 교사 데이터를 활용하기 전에 주변에 있는 데이터들을 활용해 선학습(Pre-Training)을 수행한 후, 마지막으로 교사데이터를 활용하여 최종 성능을 올리는 방식을 취하게 된다. 즉 적은 비용으로 구할 수 있는 일반 데이터들을 활용해 성능을 향상시킬 수 있는 토대를 제공한다.

6. 맺음말

최근의 심층학습의 발전과 이를 이용한 기술의 발달을 보면, 과거 디지털 혁명의 시기와 많은 부분 공통점을 가짐을 발견할 수 있다. 아날로그 정보를 디지털 정보로 바꾼 후 정보처리를 수행하는 변화의 구조가 디지털 혁명의 핵심이었다면, 향후의 정보처리의 흐름은 디지털 정보에서 의미(Semantic) 정보로 바꾼 후 그 의미에서부터 정보처리가 일어나는 방식으로 큰 흐름이 바뀔 것으로 보인다(그림 3). 디지털 정보의 의미정보로 바꾸는 기술의 핵심에 바로 심층학습

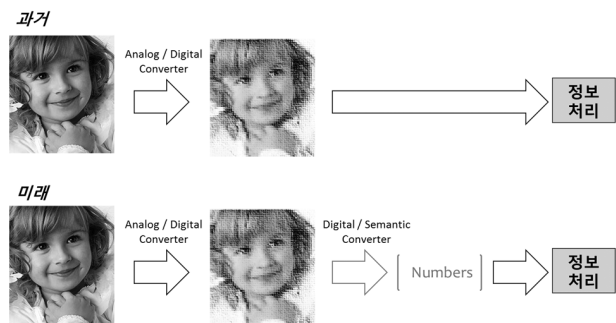


그림 3 아날로그-디지털 혁명과 디지털-시맨틱의 변화의 유사성 및 미래 정보처리 흐름

기술이 존재한다. 많은 시간동안 다량의 양질의 데이터를 활용해 구축한 디지털-의미정보 변환 기술이 향후 ICT 기업의 핵심 자산이 될 것으로 보인다.

심층학습 기술은 신경망을 어떻게 디자인하고 어떤 종류의 신경망과 연결하느냐에 따라 과거에는 상상할 수 없었던 서비스를 개발해 낼 수 있는 기회 역시 제공한다. 기술 자체가 여러 연구자들에 의해 오픈소스 형태로 배포되고 있고, 데이터 역시 인터넷을 활용한다면 쉽게 모을 수 있기 때문에 아이디어와 창의력만 있다면 얼마든지 ‘지능’을 만들어 볼 수 있는 시대가 되었다. 심층학습 기술을 활용한 다양하고 참신한 지능의 개발과 서비스 발굴을 기대해 본다.

참고문헌

- [1] 장병탁, 여무송, “Cognitive Computing I: Multisensory Perceptual Intelligence - 실세계 지각행동 지능”, 정보과학회지, v.30, no.1, 75-87, 2012년 1월
- [2] Rosenblatt, Frank, “The Perceptron--a perceiving and recognizing automaton”, Report 85-460-1, Cornell Aeronautical Laboratory
- [3] Rosenblatt, Frank. x., “Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms”, Spartan Books, Washington DC, 1961

- [4] Rumelhart, David E., Geoffrey E. Hinton, and R. J. Williams, “Learning Internal Representations by Error Propagation”, Parallel distributed processing: Explorations in the microstructure of cognition, Volume 1: Foundations. MIT Press, 1986.
- [5] Yoshua Bengio, Ian J. Goodfellow, Aaron Courville, “Deep Learning”, Book in preparation for MIT Press, 2015. url : <http://www.iro.umontreal.ca/~bengioy/dlbook>
- [6] M.D. Zeiler, R. Fergus, “Visualizing and Understanding Convolutional Networks”, ECCV 2014
- [7] url : <http://techcrunch.com/2014/11/18/new-google-research-project-can-auto-caption-complex-images/>
- [8] 정상근, “인공지능과 딥러닝의 역사”, TECH M, 3월호

약 력



정 상 근

1999~2004 포항공과대학교, 컴퓨터공학 학사
 2004~2006 포항공과대학교, 컴퓨터공학 석사
 2006~2010 포항공과대학교, 컴퓨터공학 박사
 2010~2012 삼성전자 책임연구원
 2012~2014 한국전자통신연구원(ETRI) 선임연구원
 2014~현재 SKT 미래기술원

관심분야: 인공지능, 딥러닝, 자연어처리

Email : hugman@sk.com, hugmanskj@gmail.com